Politechnika Wrocławska

Identyfikacja nieliniowych systemów dynamicznych z wykorzystaniem rekurencyjnych sieci neuronowych

Mateusz Gwizdak 252945
Maciej Krystyniak 252882
Robert Świerc 254028

HR EXCELLENCE IN RESEARCH

Politechnika Wrocławska

Agenda:

1. Wstęp teoretyczny:
   - Co to są rekurencyjne sieci neuronowe?
   - Co je wyróżnia?
   - Jak działają?
   - Zastosowania
   - LSTM i GRU
2. Opis wykorzystanych narzędzi.
3. Przygotowania wstępne:
   - Jak przygotować dane?
   - Jak przebiega uczenie?
   - Wykorzystywany model sieci.
4. Wykorzystane dane i modele.
5. Przebieg i wyniki badań.
6. Podsumowanie

Rekurencyjne sieci neuronowe

Sieć neuronowa

Prosta sieć neuronowa składa się z 3 warstw:

- Wejściowa,
- Ukryta,
- Wyjściowa.

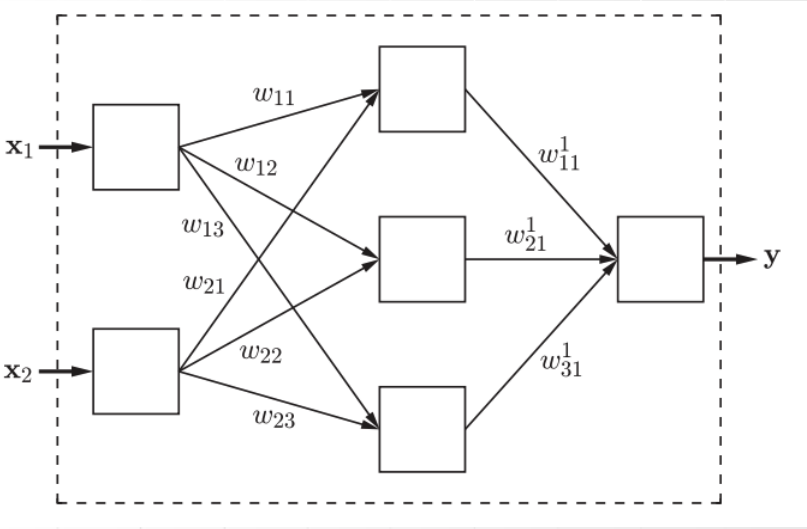

Rekurencyjna sieć neuronowa

Model neuronu:

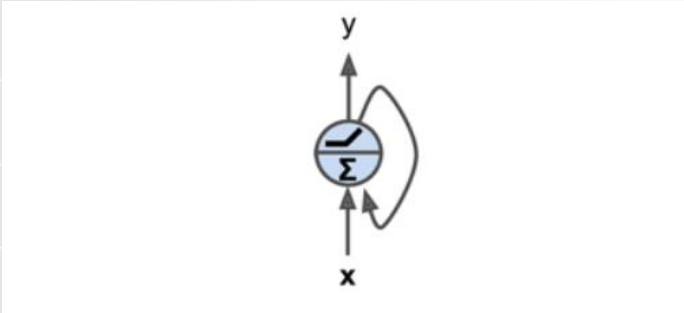

Model sieci:

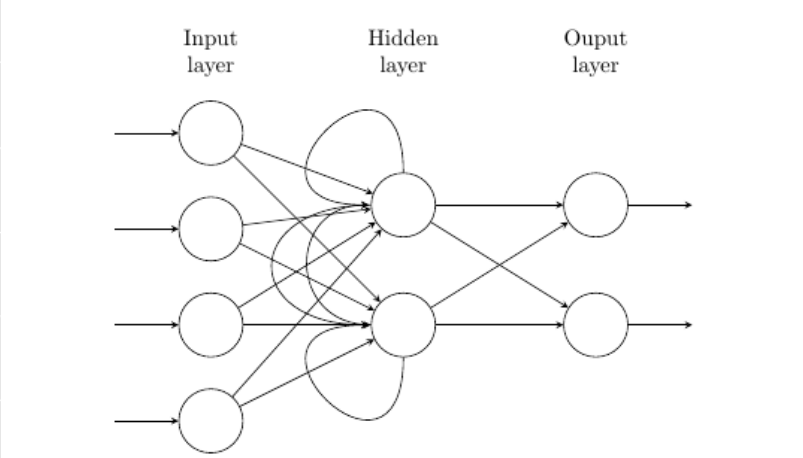

Politechnika Wrocławska

Rekurencyjne sieci neuronowe – zastosowania

- Przetwarzanie sekwencyjnych danych – danych gdzie poprzednie próbki mają wpływ na teraźniejszość

- Analiza języka naturalnego:
- Chat GPT(Transformer),
- Rozpoznawanie mowy .

- Przetwarzanie sekwencji czasowych:
- Ceny akcji,
- Pogoda.

- Sieci hybrydowe.

LSTM a GRU

LSTM

- Reprezentuje zależności krótko I długotrwałe.
- Na podstawie krótkotrwałych filtruje dane.
- Składa się z trzech bram:
  - Bramka wejściowa - przyjmuje dane, które dodawane są do stanu długotrwałego.
  - Bramka zapomnij – decyduje jakie dane z przeszłości mają być zapomniane.
  - Bramka wyjściowa - filtracja I wyrzucenie nowego stanu krótkoterminowego.

GRU

- Analogicznie reprezentuje zależności krótko I długotrwałe.
- Znacznie prostsza architektura niż w przypadku LSTM
- Składa się z dwóch bram:
  - Bramka aktualizacji – ile informacji z poprzedniego stanu użyć do aktualizacji obecnego stanu
  - Bramka resetowania – ile informacji z poprzedniego stanu ma zostać zapomniane
  - -Generacja wartości [0, 1]

Politechnika Wrocławska

Wykorzystane narzędzia

- Język programowania python™
- Biblioteka TensorFlow™
- Architektura NVIDIA CUDA
- Klasyczne biblioteki do manipulacji i analizy danych typu NumPy i pandas
- Pomocnicze biblioteki matplotlib czy

Politechnika Wrocławska

Preprocessing

- Podział zbiorów na treningowy, walidacyjny i testowy (proporcje 70:20:10)
- Standaryzacja danych
- Podział na batch (batch_size)
- Generacja okien

Politechnika Wrocławska

Uczenie RNN

- Przetwarzanie kolejnych batchy zbioru treningowego
- Sprawdzanie błędu na zbiorze walidacyjnym
- Ewentualne przerwanie uczenia gdy kolejne epoki nie dają lepszego wyniku wybranego pomiaru błędu
- Następuje zapisanie na dysku uzyskanego modelu i jego historii uczenia

Politechnika Wrocławska

Przykład wykorzystywanego modelu RNN

```
multi_lstm_model = tf.keras.Sequential([
    # Shape [batch, time, features] => [batch, lstm_units].
    tf.keras.layers.LSTM(units = UNITS, return_sequences=False, activation = ACTIVATION),
    # Shape => [batch, out_steps*features].
    tf.keras.layers.Dense(OUT_STEPS*num_features,
                          kernel_initializer=tf.initializers.zeros()),
    # Shape => [batch, out_steps, features].
    tf.keras.layers.Reshape([OUT_STEPS, num_features])
])
```

Politechnika Wrocławska

Wykorzystane dane

- Badanie wibracji skrzydeł samolotu F-16
- Pomiary meteorologiczne w latach 2009-2016
- Wygenerowane modele zależne czasowo
- Wygenerowane modele zależne czasowo z zakłóceniami
- Wygenerowany sygnał o zmiennej częstotliwości (chirp)

Politechnika Wrocławska

Przebieg badań

Politechnika Wrocławska

F16

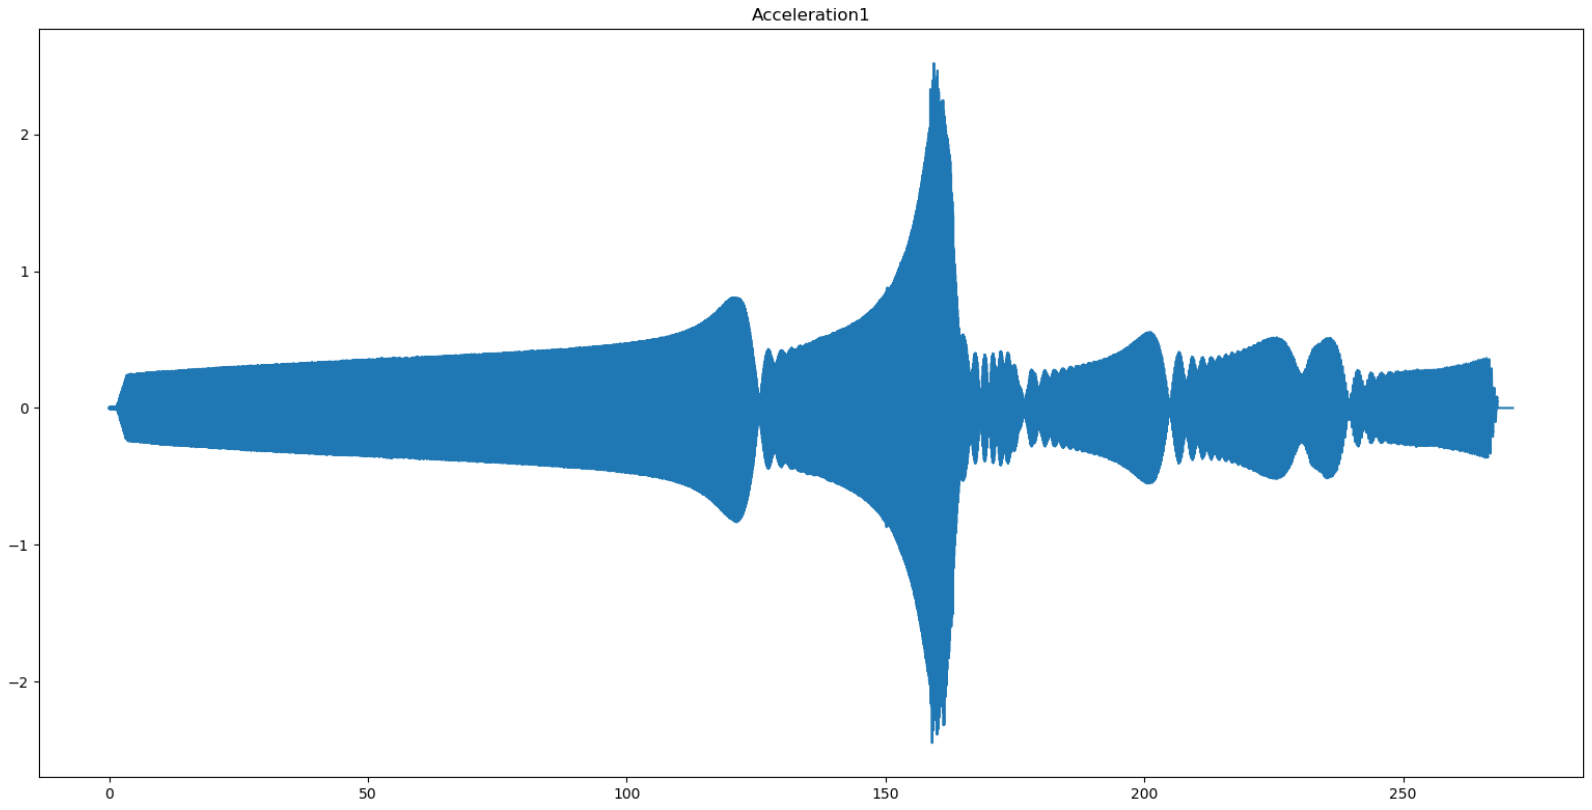

F16

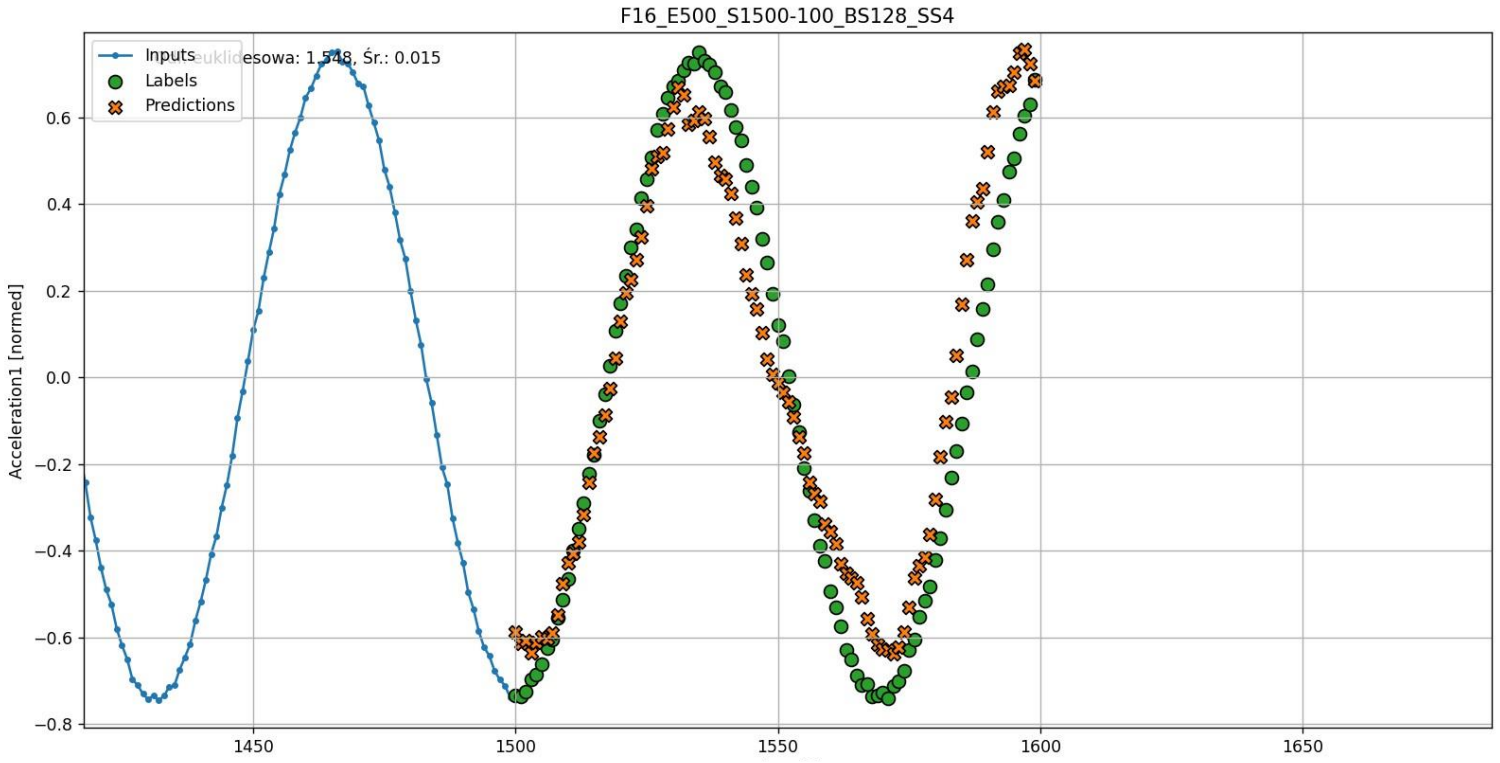
F16_E500_S1500-100_BS128_SS4
Inputs
Labels
Predictions
esowa: 1.548, Śr.: 0.015
Acceleration1 [normed]
0.6
0.4
0.2
0.0
−0.2
−0.4
−0.6
−0.8
1450
1500
1550
1600
1650

Politechnika Wrocławska

F16

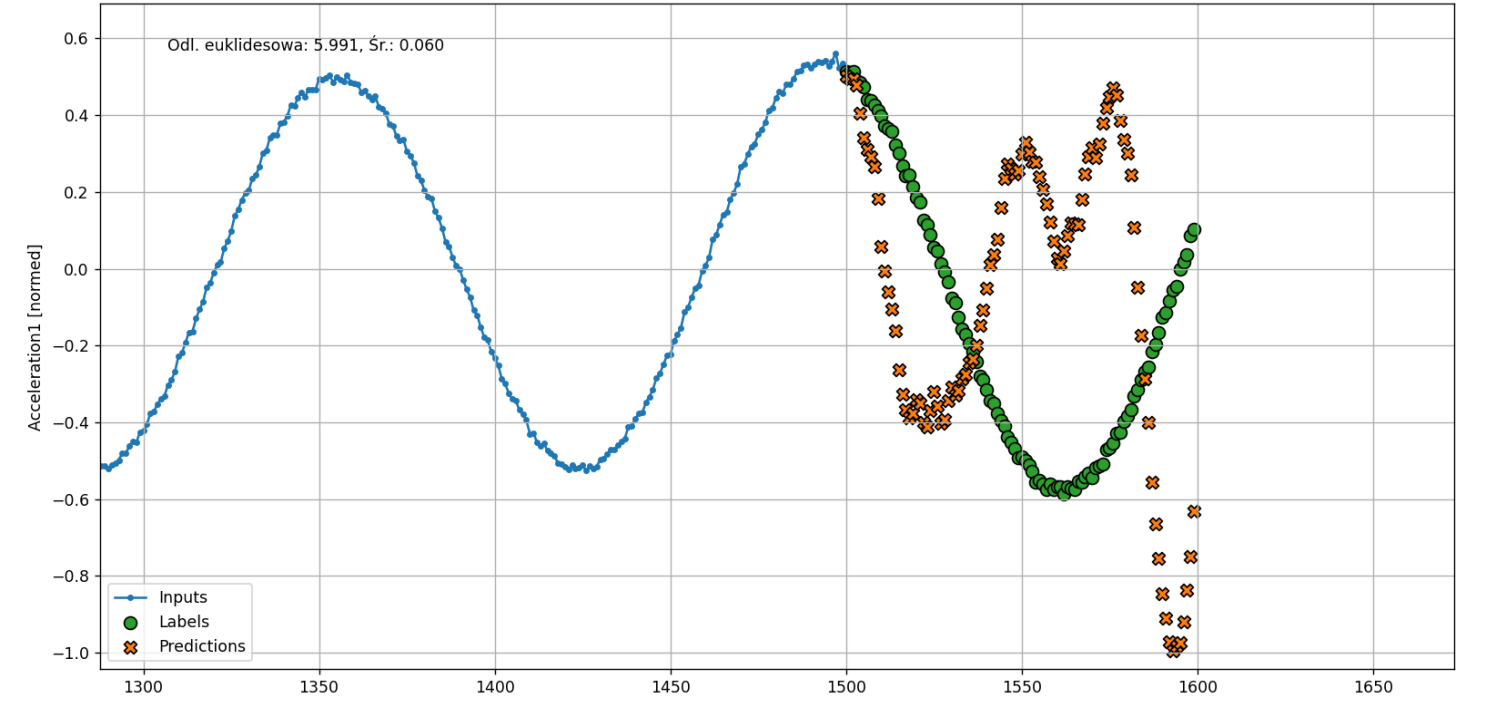

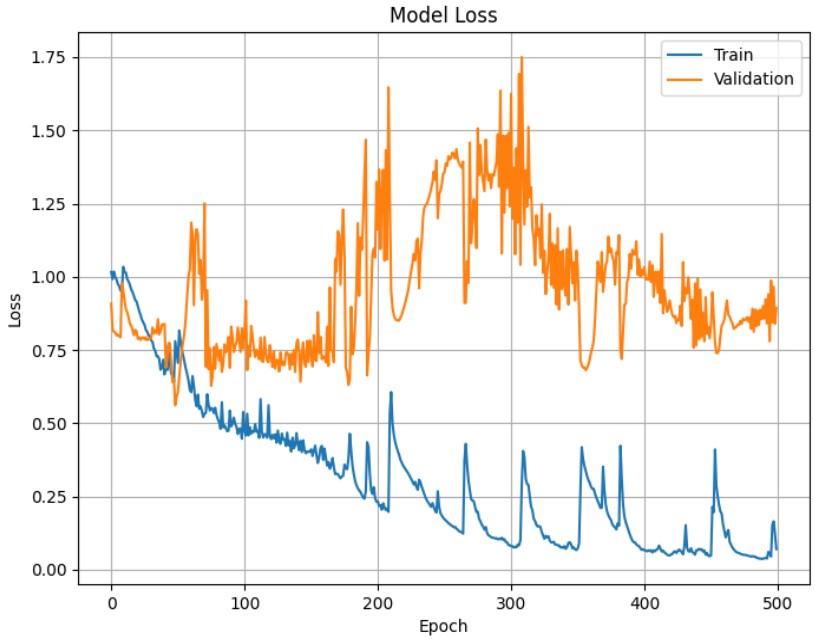

Politechnika Wrocławska

F16

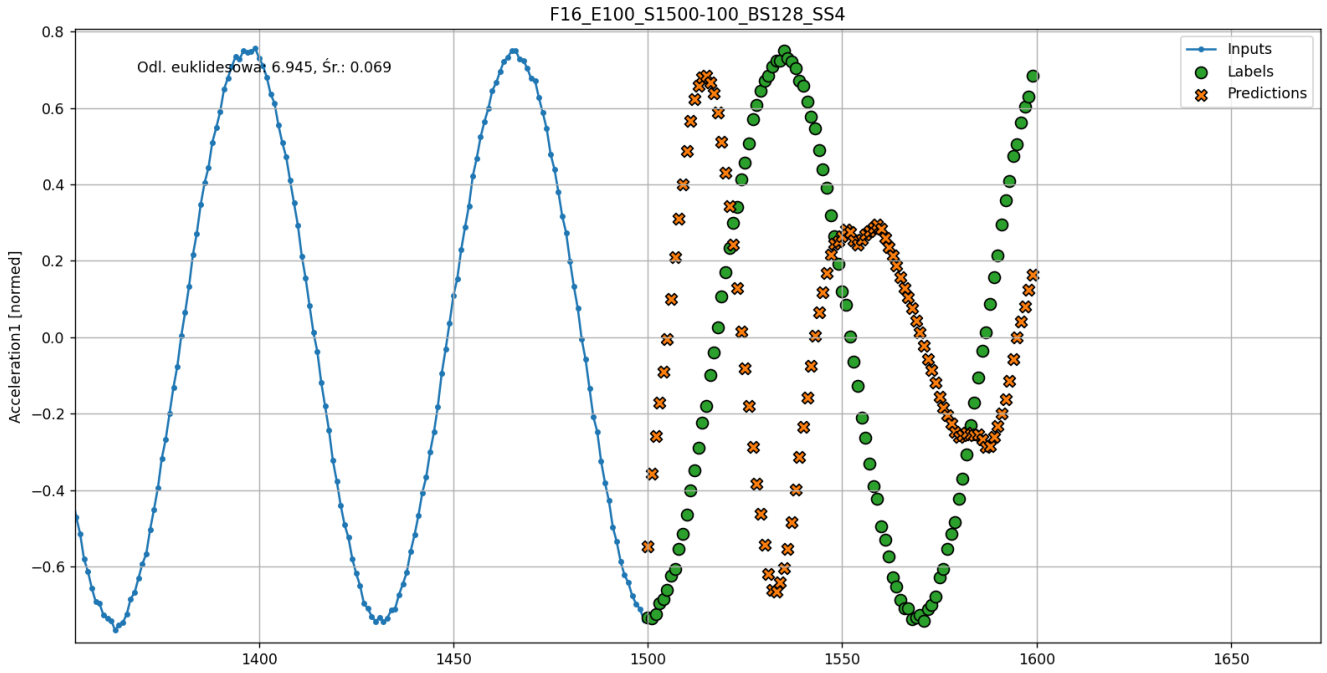

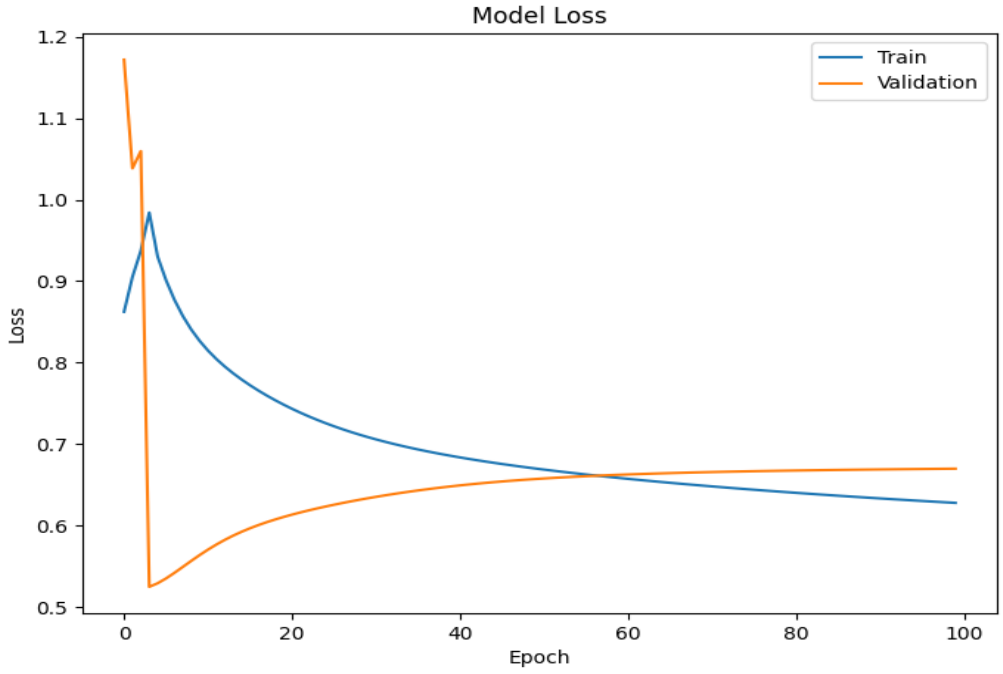

F16

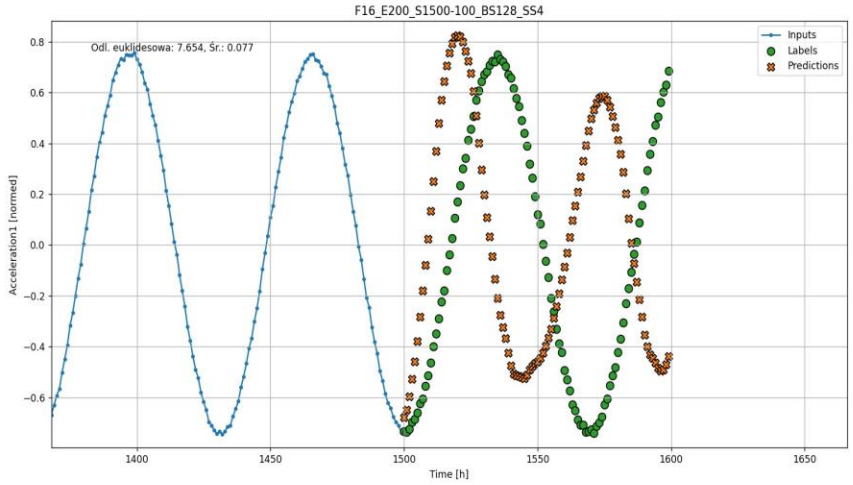
F16_E200_S1500-100_BS128_SS4
Odl. euklidesowa: 7.654, Śr.: 0.077
Inputs
Labels
Predictions
Acceleration1 [normed]
Time [h]

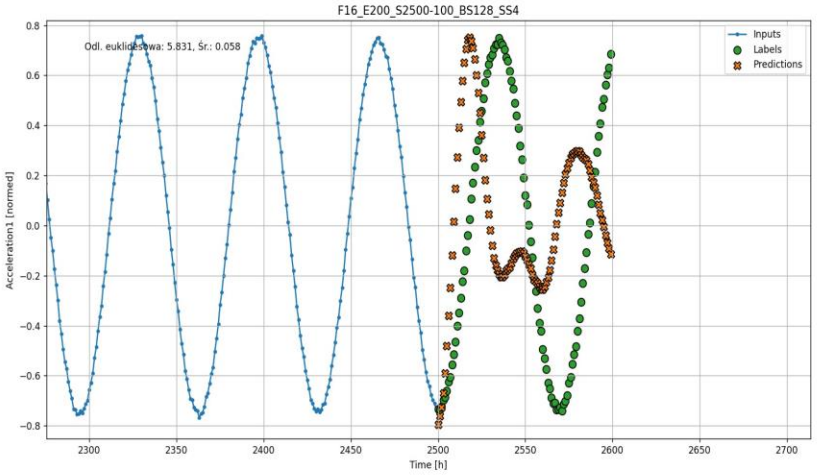
F16_E200_S2500-100_BS128_SS4
Odl. euklidesowa: 5.831, Śr.: 0.058
Inputs
Labels
Predictions
Acceleration1 [normed]
Time [h]

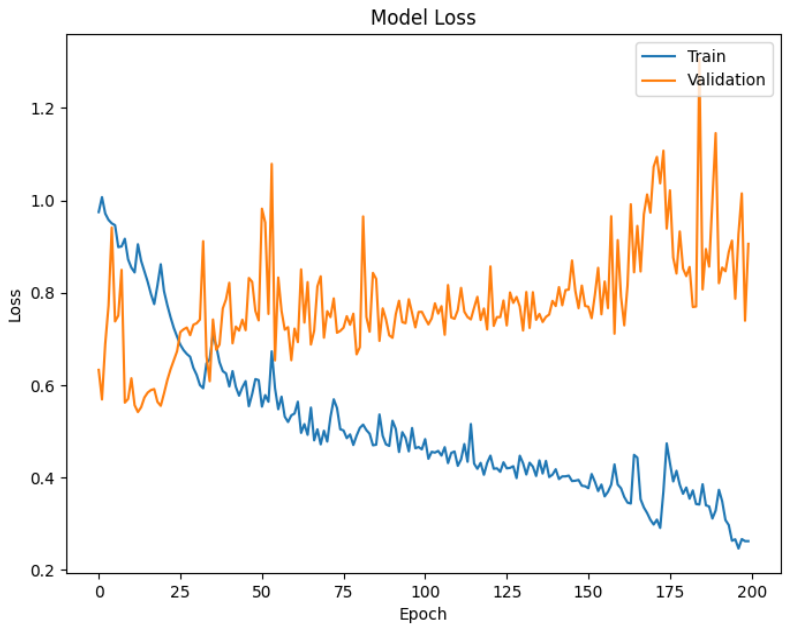
Model Loss
Train
Validation
Loss
Epoch

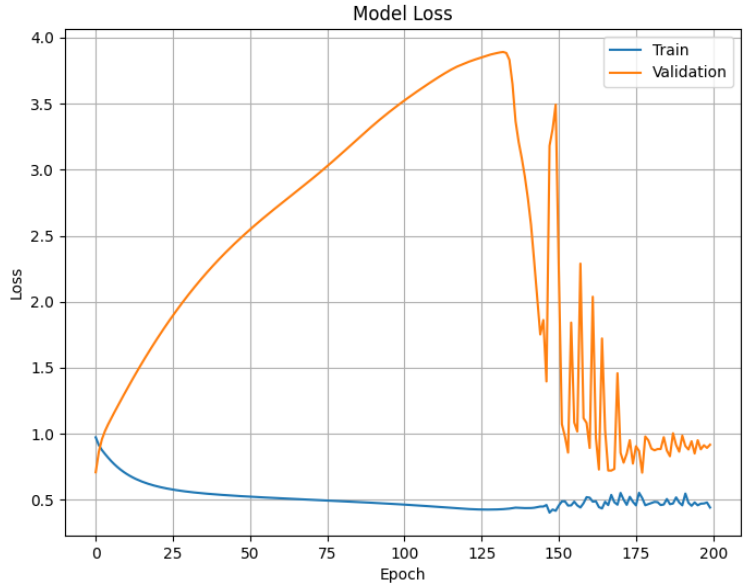
Model Loss
Train
Validation
Loss
Epoch

F16

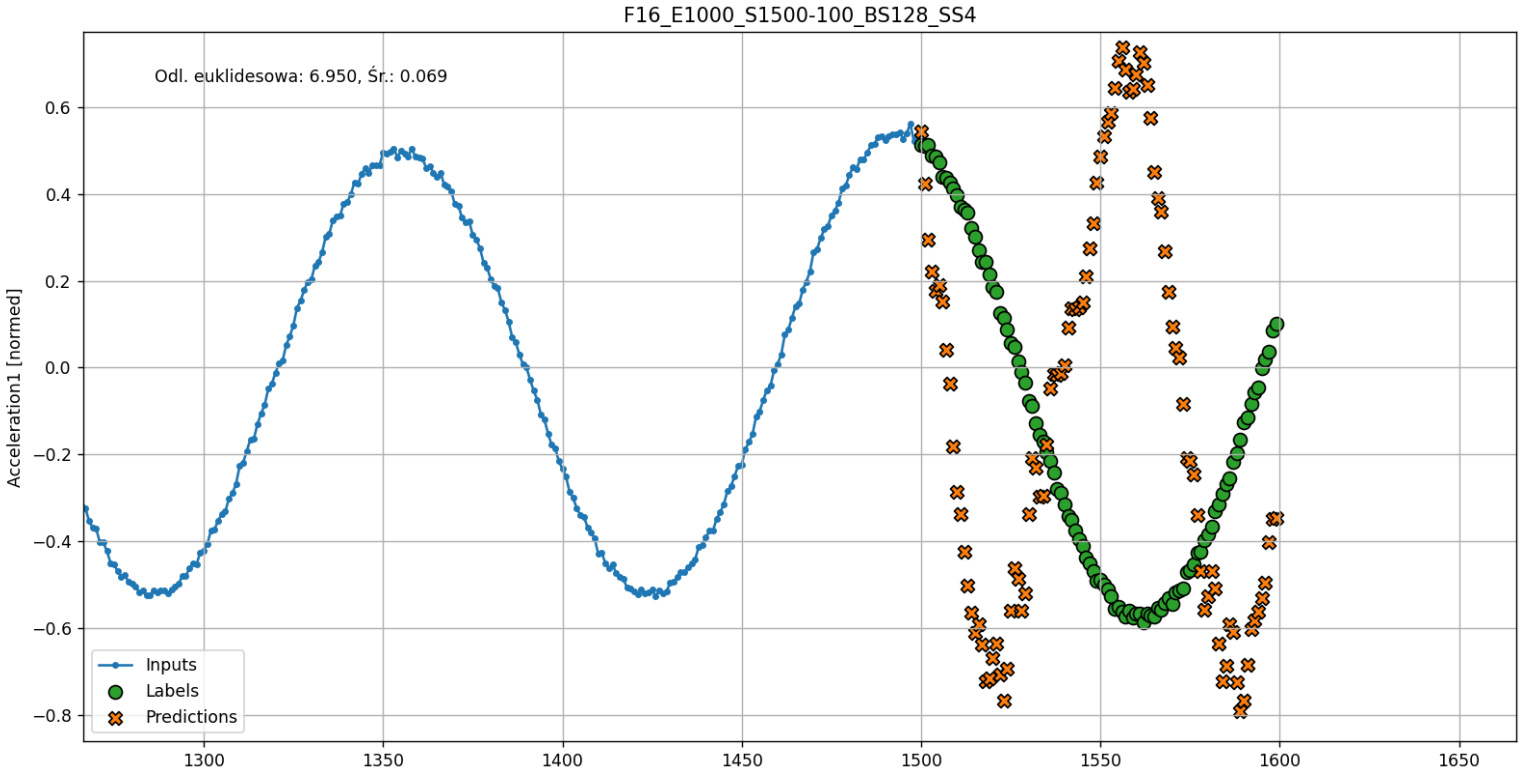
F16_E1000_S1500-100_BS128_SS4
Odl. euklidesowa: 6.950, Śr.: 0.069
Acceleration1 [normed]
0.6
0.4
0.2
0.0
−0.2
−0.4
−0.6
−0.8
1300
1350
1400
1450
1500
1550
1600
1650
Inputs
Labels
Predictions

Politechnika Wrocławska

Wygenerowane modele

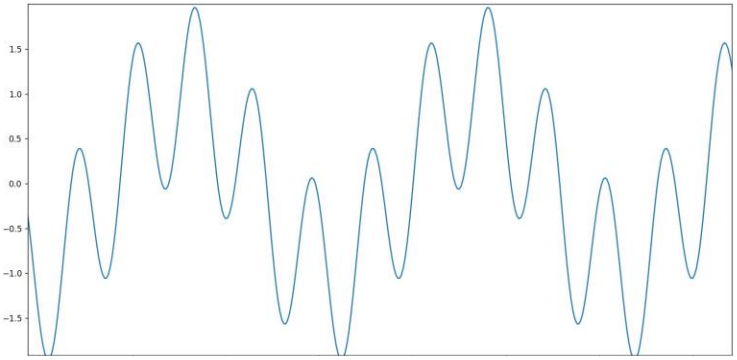

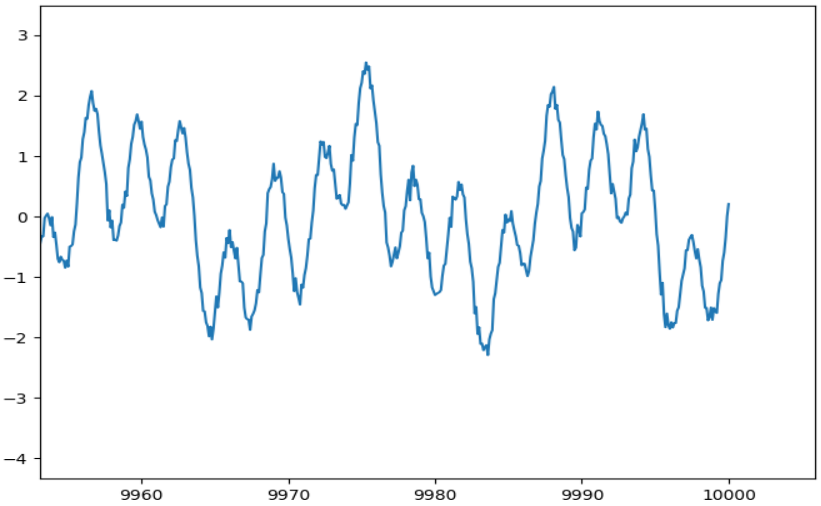

Wygenerowane modele: sin(x') + cos(x'')

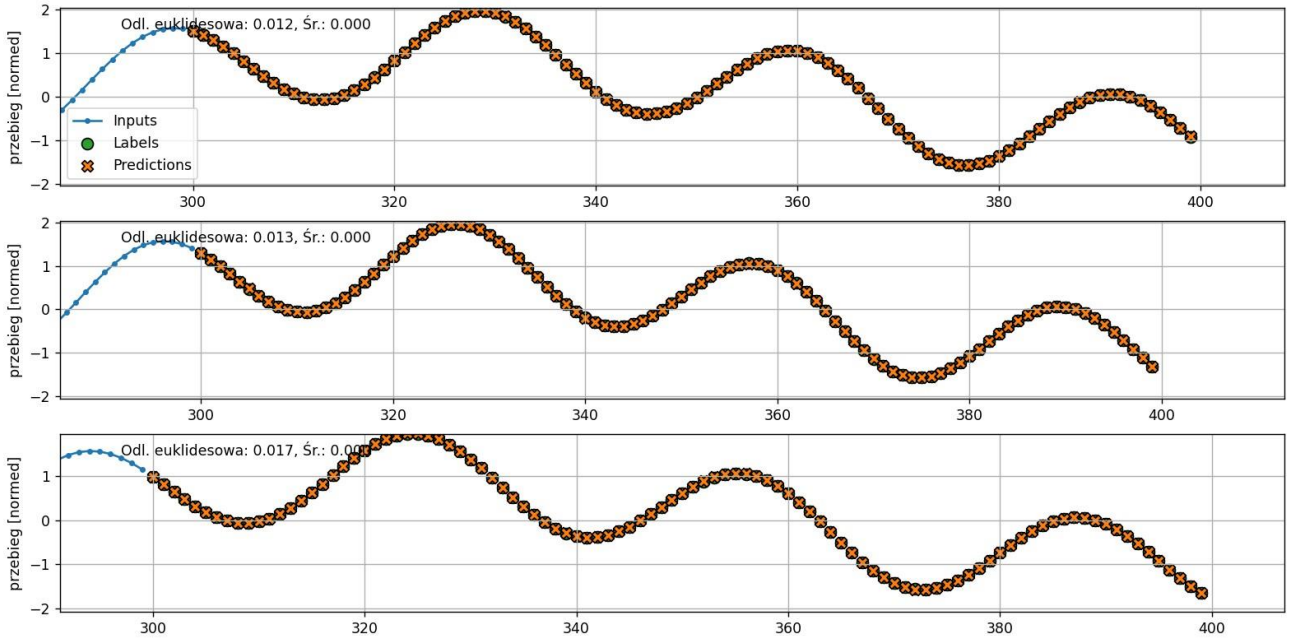

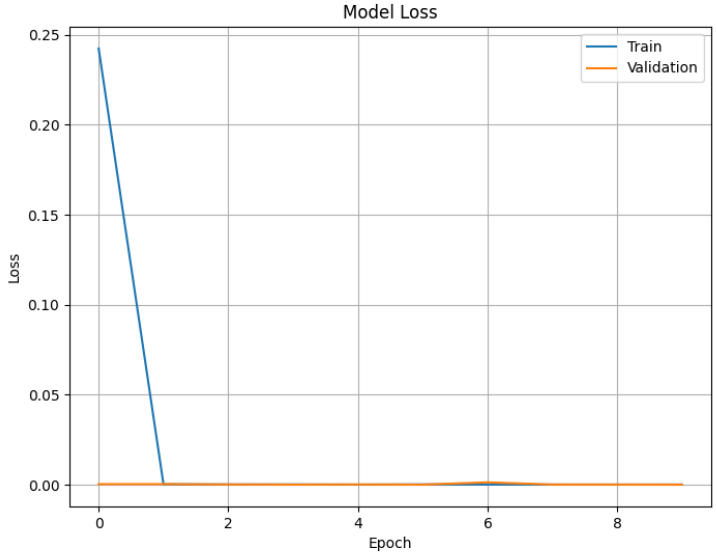

Wygenerowane modele: zaszumione sin(x') + cos(x'')

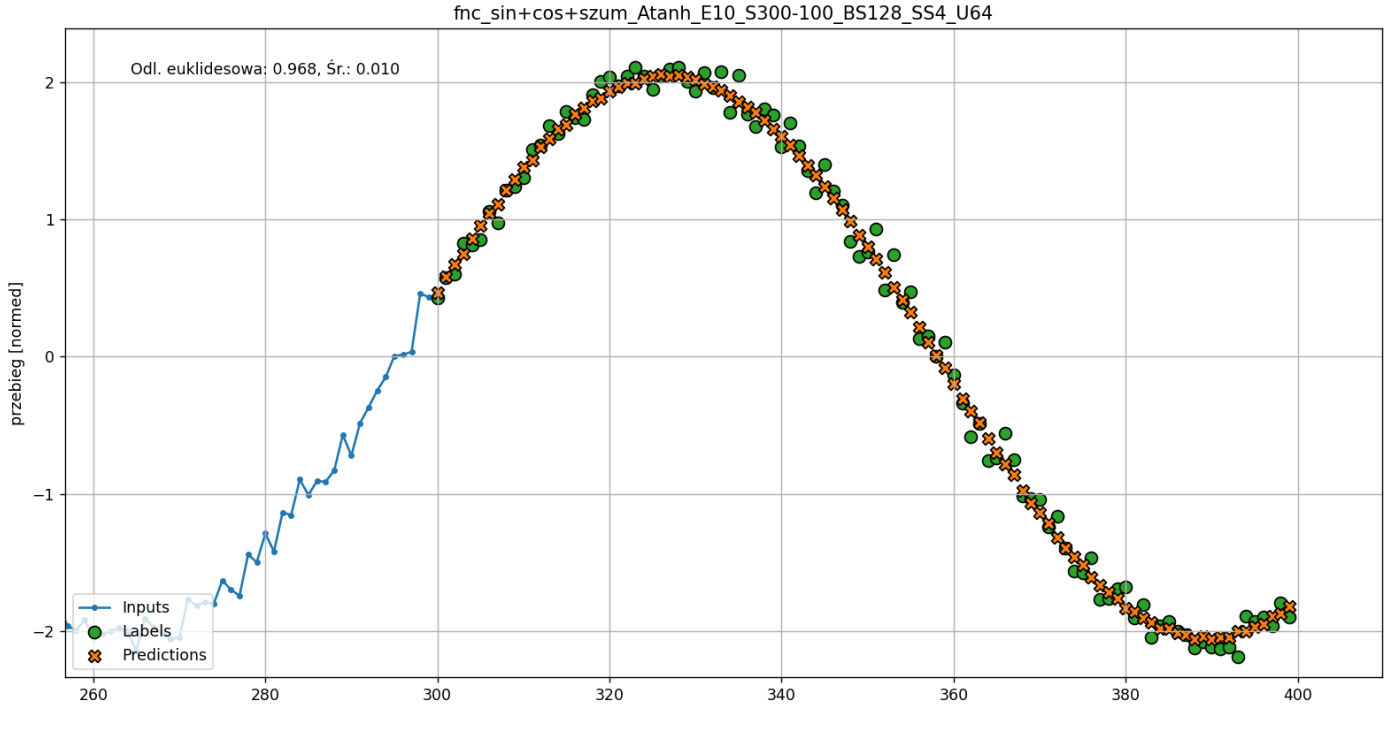

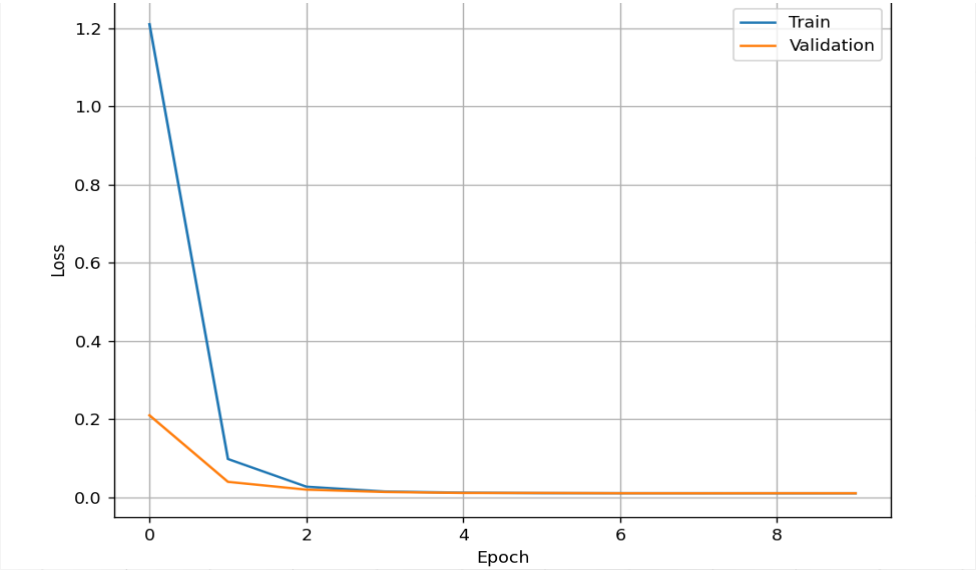

Wygenerowane modele: zaszumione sin(x') + cos(x'')

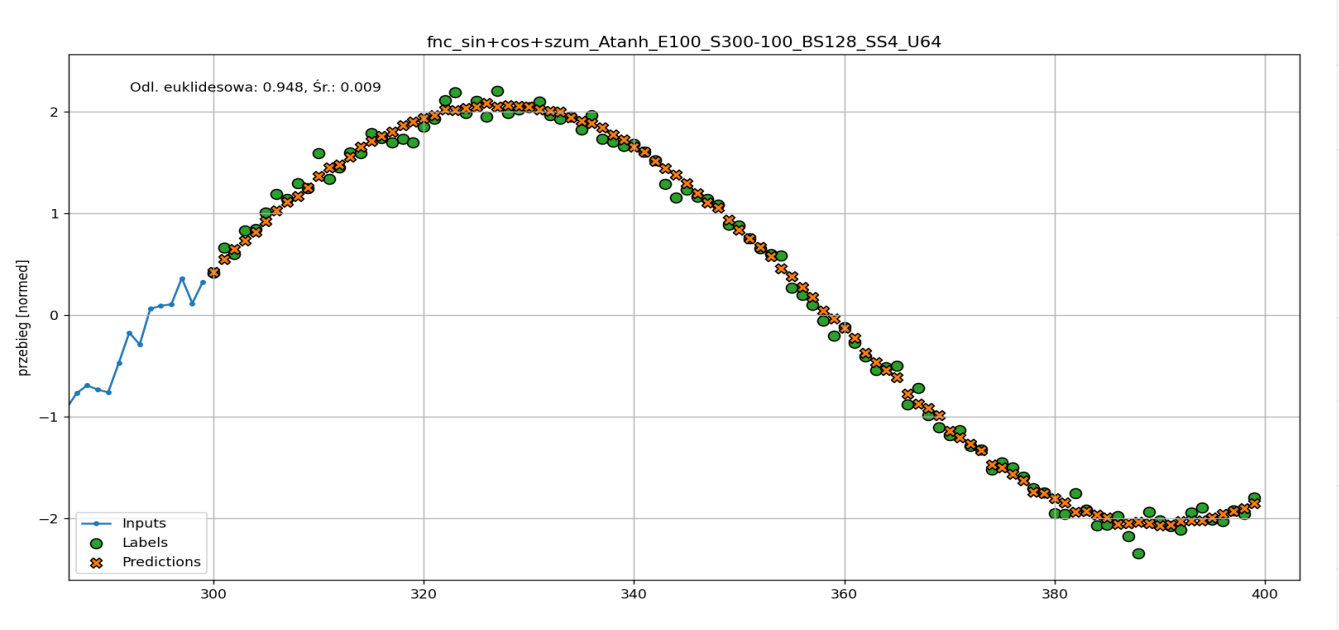

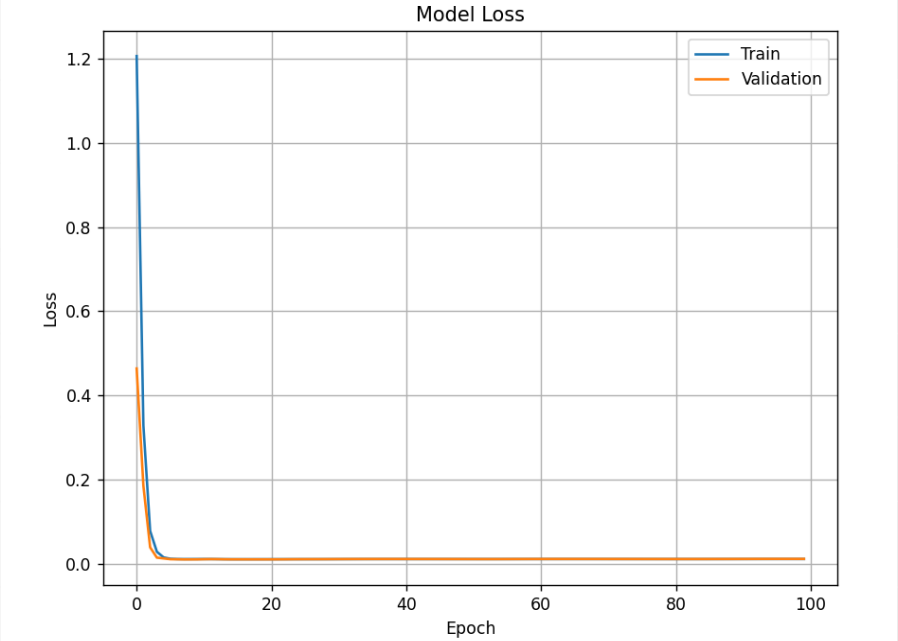

Wygenerowane modele: chirp

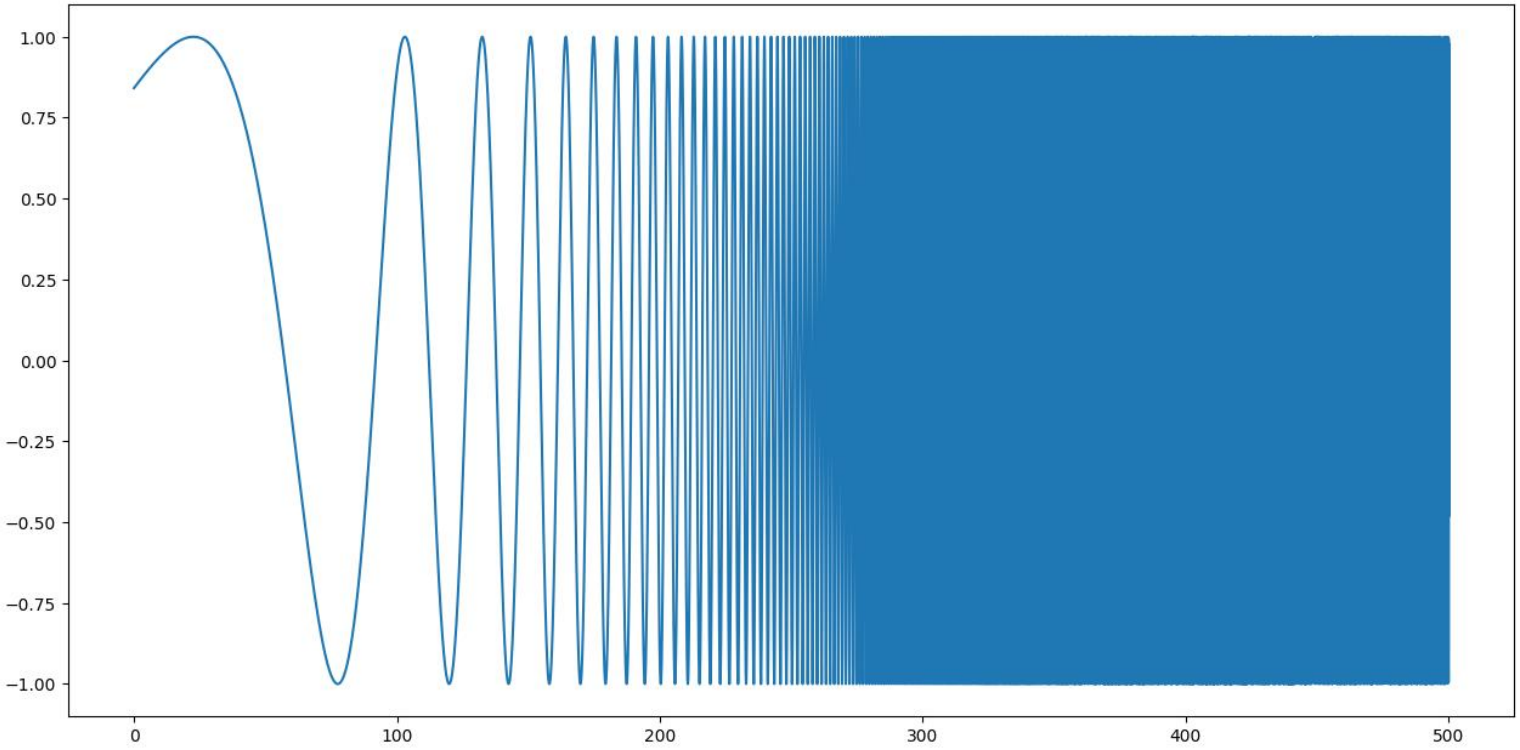

Wygenerowane modele: chirp

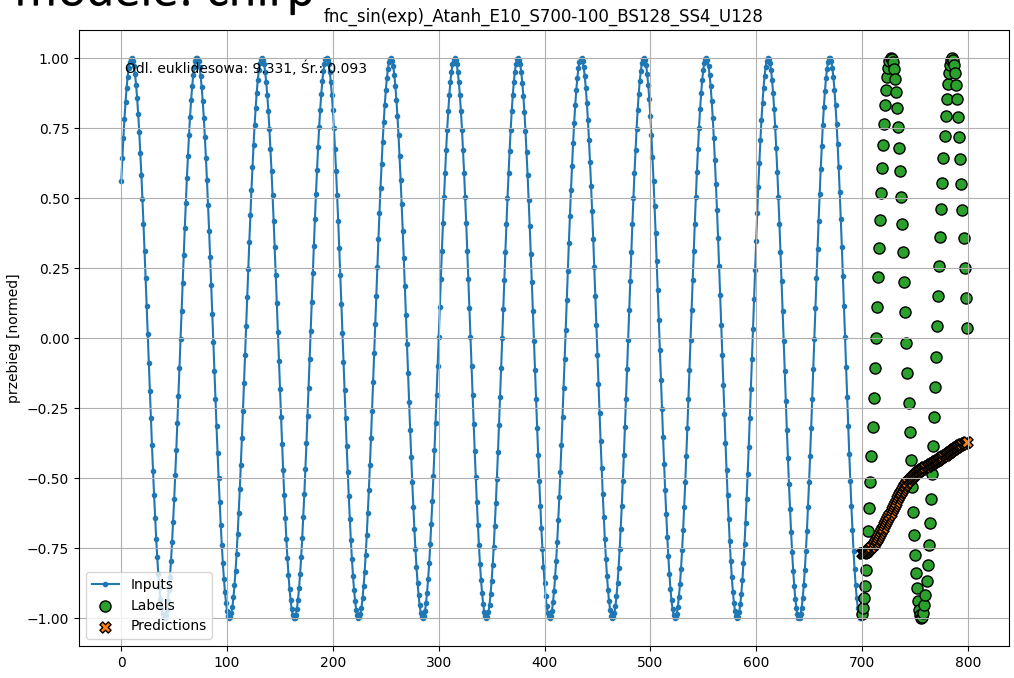

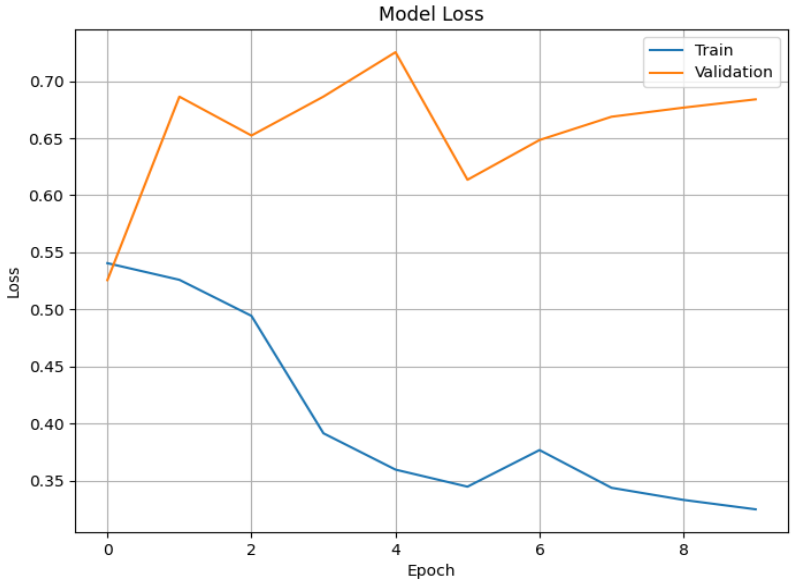

Wygenerowane modele: chirp

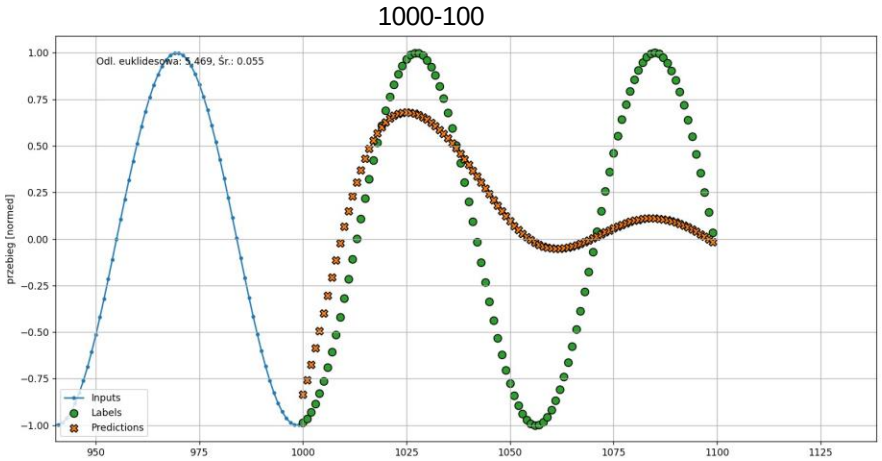

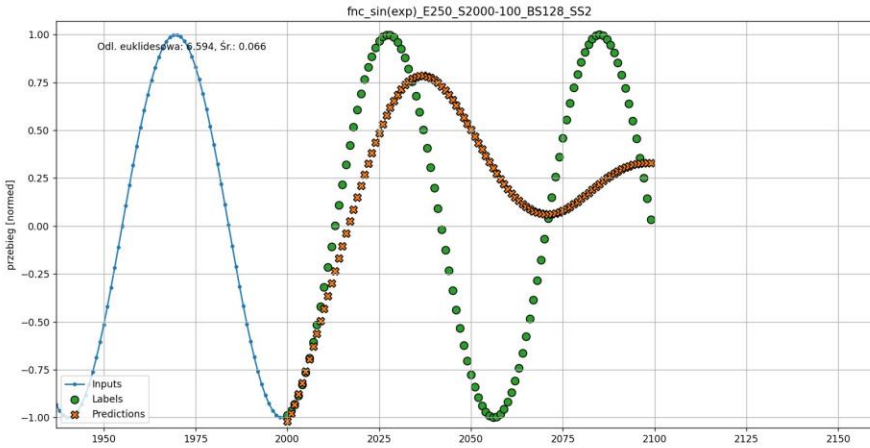

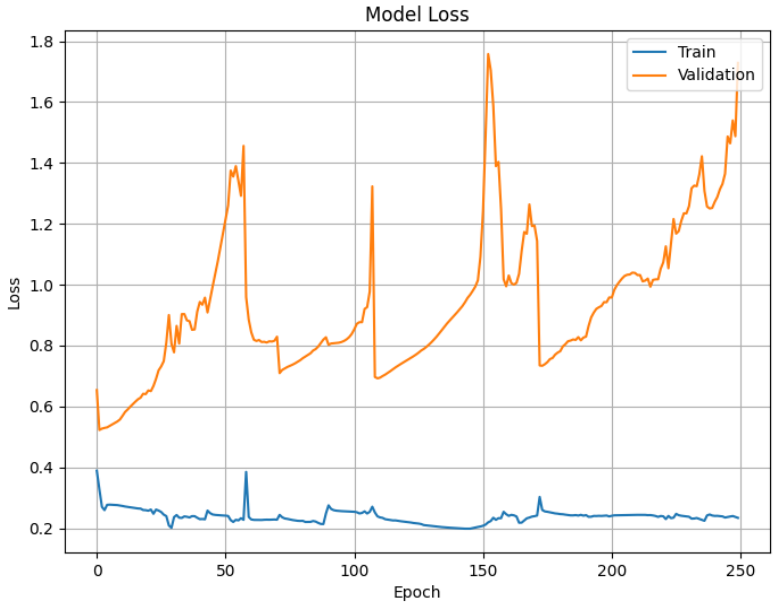

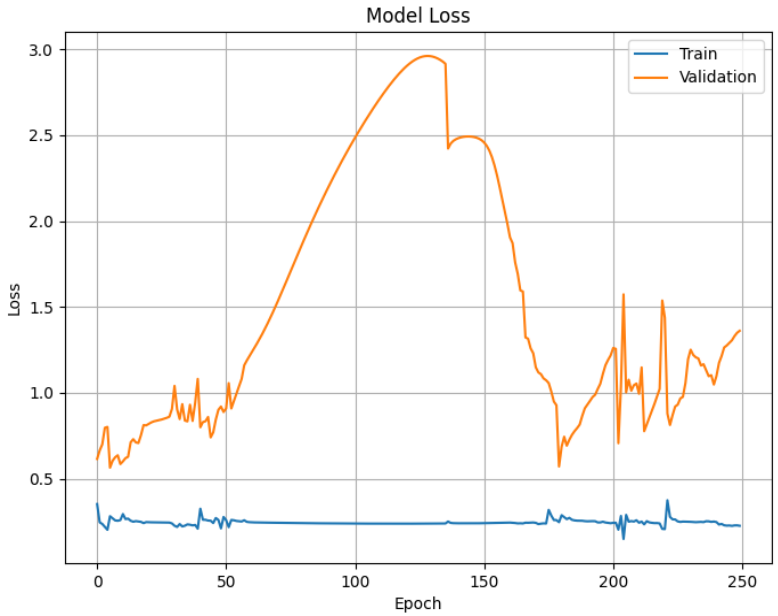

Wygenerowane modele: chirp

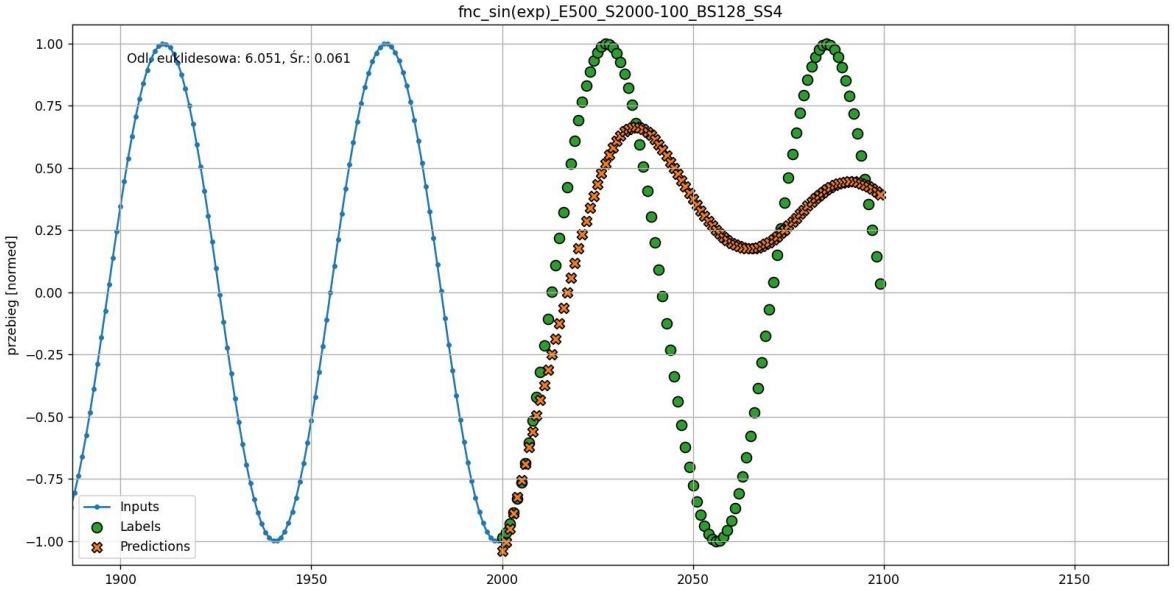

Politechnika Wrocławska

Pogoda

Pogoda

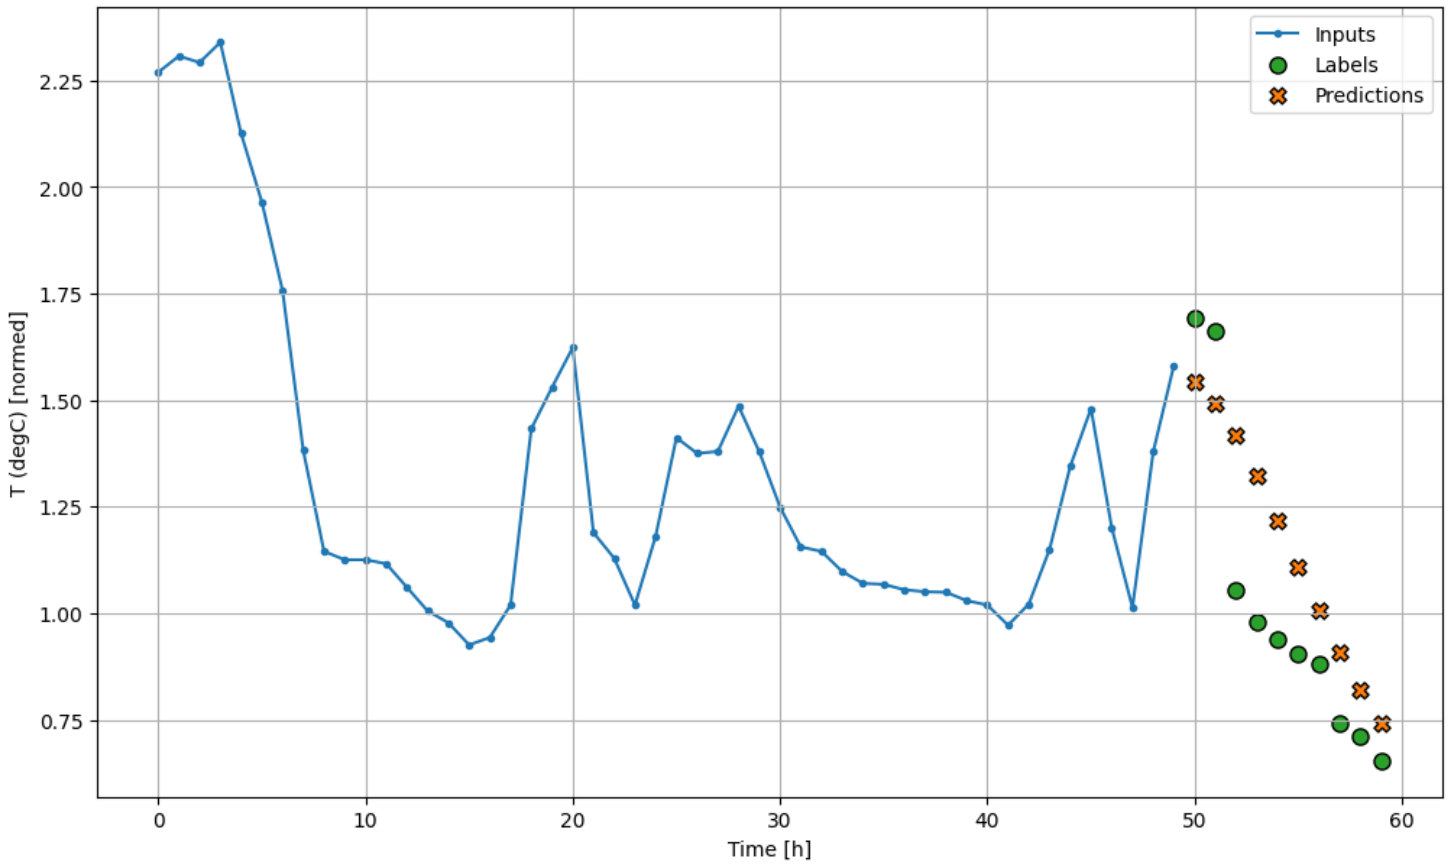
Inputs
Labels
Predictions
T (degC) [normed]
Time [h]
2.25
2.00
1.75
1.50
1.25
1.00
0.75
0
10
20
30
40
50
60

Pogoda

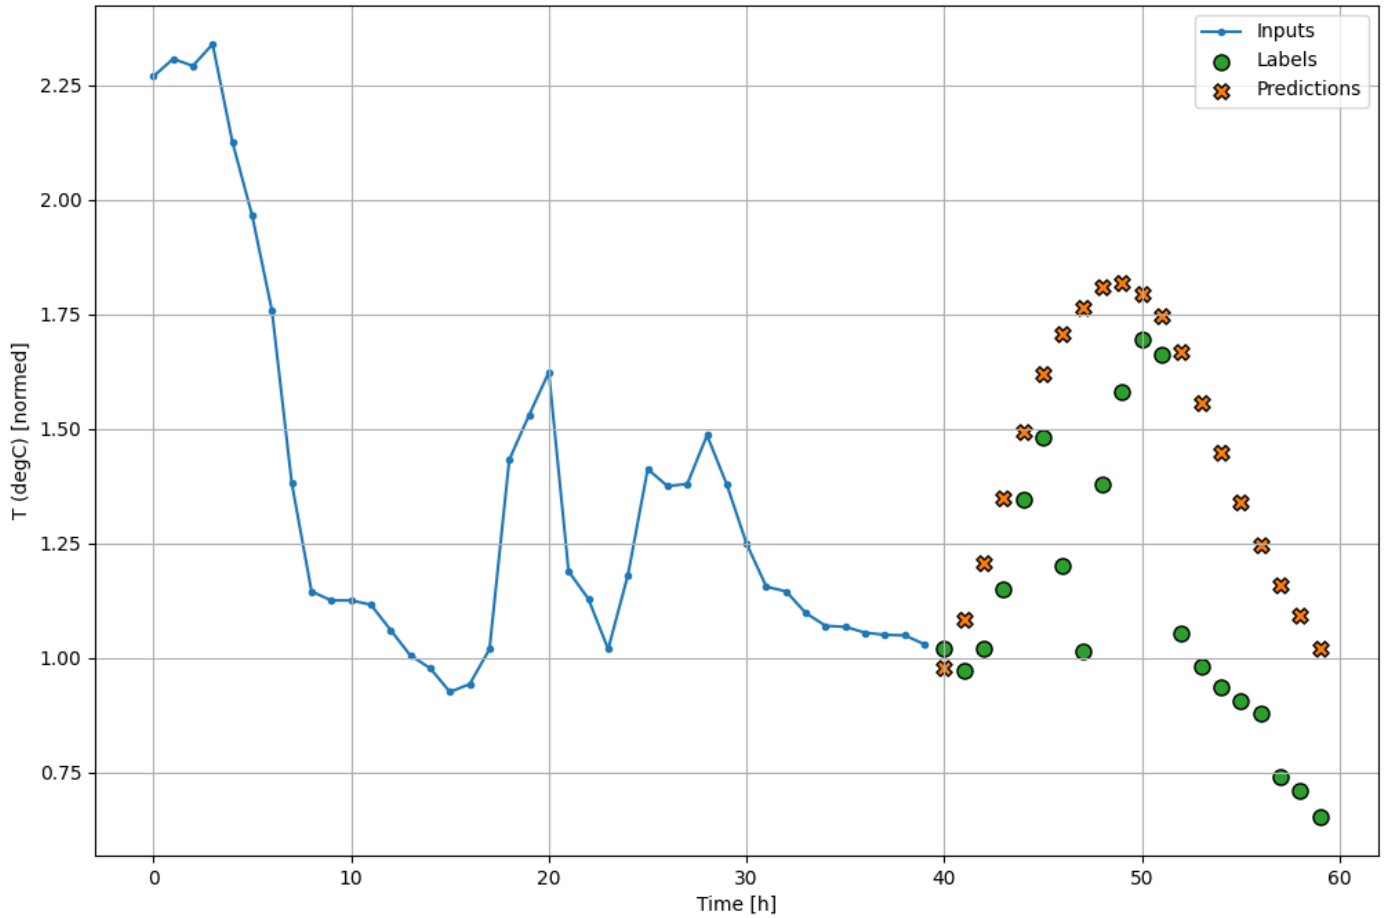
Inputs
Labels
Predictions
T (degC) [normed]
Time [h]
2.25
2.00
1.75
1.50
1.25
1.00
0.75
0
10
20
30
40
50
60

Politechnika Wrocławska

Podsumowanie z realizacji projektu

- RNN to narzędzie z dużym potencjałem,
- Wyniki, które otrzymaliśmy nie są (dla nas) zadowalające,
- Praca nad zwiększeniem dokładności (bez odpowiedniego doświadczenia) wymaga ogromnych nakładów czasu,

Politechnika Wrocławska

Pytania?

Politechnika Wrocławska

Dziękujemy za uwagę.